

In diesem Projekt habe ich einen RAG-basierten KI-Chatbot entwickelt.

Der Benutzer kann PDF- oder Word-Dateien hochladen und Fragen zu diesen Dokumenten stellen.

Die Dokumente werden zuerst verarbeitet und in kleinere Textabschnitte aufgeteilt. Danach werden Embeddings erstellt und in FAISS gespeichert.

Wenn der Benutzer eine Frage stellt, findet FAISS die relevantesten Textabschnitte. Diese Informationen werden dann zusammen mit der Frage an das Sprachmodell geschickt, das die Antwort erstellt.

Zusätzlich habe ich GraphRAG und HyDE integriert, um die Qualität der Suche und der Antworten zu verbessern.

Für das Frontend habe ich Streamlit verwendet und das gesamte Projekt mit Docker containerisiert.

1. Was ist RAG?

RAG kombiniert Dokumentensuche mit einem Sprachmodell. Das System findet zuerst die relevanten Informationen und erstellt danach die Antwort.

2. Warum FAISS?

FAISS ist sehr schnell bei der Suche nach ähnlichen Embeddings. Deshalb habe ich FAISS verwendet.

3. Was ist ein Embedding?

Ein Embedding ist eine numerische Darstellung eines Textes. So kann das System ähnliche Inhalte finden.

4. Warum Chunking?

Ich teile den Text in kleinere Abschnitte auf. So kann das Modell die Informationen besser verarbeiten.

5. Was ist GraphRAG?

GraphRAG nutzt zusätzlich einen Knowledge Graph. Dadurch kann das System Beziehungen zwischen Informationen besser verstehen.

6. Was ist HyDE?

HyDE erstellt zuerst eine hypothetische Antwort. Das verbessert anschließend die Suche nach relevanten Dokumenten.

7. Warum Docker?

Docker sorgt dafür, dass die Anwendung auf jedem System gleich läuft und einfach bereitgestellt werden kann.

8. Warum Flan-T5?

Flan-T5 eignet sich gut für Frage-Antwort-Aufgaben und ist einfach lokal einzusetzen.

9. Wie funktioniert der Workflow?

Dokument hochladen, Text verarbeiten, Embeddings erstellen, mit FAISS suchen und anschließend die Antwort mit dem Sprachmodell generieren.

10. Was würden Sie verbessern?



Ich würde eine bessere Hybrid-Suche mit BM25 und Vektor-Suche einsetzen, außerdem ein größeres Sprachmodell verwenden und den Knowledge Graph weiter verbessern. So könnte die Qualität der Antworten noch besser werden.

11. Was ist der Unterschied zwischen RAG und GraphRAG?

RAG findet ähnliche Texte. GraphRAG nutzt zusätzlich einen Knowledge Graph und versteht auch die Beziehungen zwischen den Informationen.

12. Warum ist RAG besser als ein normales LLM?

RAG nutzt zusätzlich Dokumente. Deshalb sind die Antworten genauer und Halluzinationen werden reduziert.



Burada hangi tool ne yapıyor?

Tool	Görevi
S3	PDF dosyalarını saklar
LangChain	Chunking ve RAG akışını yönetir
Titan Embeddings	Dokümanı ve soruyu embedding'e çevirir
OpenSearch	Embedding'leri saklar ve semantic search yapar
BM25	Keyword search yapar
Neo4j (GraphRAG)	Entity ilişkilerini saklar
HyDE	Soruyu zenginleştirir
Claude/Llama	Nihai cevabı üretir
FastAPI	AI servisini REST API olarak sunar
Kafka	Uzun süren işlemleri asenkron yürütür
Docker	Her servisi container haline getirir
ECR	Docker image'larını saklar
EKS	Container'ları çalıştırır ve ölçeklendirir
PostgreSQL	Metadata, kullanıcılar ve doküman bilgilerini saklar

